

CSIC 2010 웹 공격 데이터셋

샘플 크기별 비교 분석

10,000건 원본 샘플 vs 61,065건 확장 데이터 · 빅데이터분석프로젝트 실습 4-A

데이터 개요

csic2010_requests.csv		만건 버전	csic2010_requests60000.csv		6만건 버전
전체 HTTP 요청	~10,000건		전체 HTTP 요청	61,065건	
정상 (Normal)	~5,884건		정상 (Normal)	36,000건	
공격 (Anomalous)	~4,116건		공격 (Anomalous)	25,065건	
공격 비율	약 41%		공격 비율	41.0%	
GET 요청	약 7,066건		GET 요청	43,088건	
POST 요청	약 2,887건		POST 요청	17,580건	
PUT 요청	약 65건		PUT 요청	397건	

정상 vs 공격 비율 비교

만건 버전 (~10K)	6만건 버전 (61K)	핵심 관찰
41% ● 정상 ~59% ● 공격 ~41%	41% ● 정상 59% ● 공격 41%	두 데이터셋 모두 공격 비율이 약 41%로 동일합니다. 이는 CSIC 2010 원본 데이터셋의 클래스 불균형 특성이 샘플링 크기와 무관하게 일관되게 유지된다는 것을 의미합니다. 6만건 버전은 만건 대비 약 6.1배 규모이며, 정상/공격 비율이 거의 동일하게 증폭되어 있습니다 (Normal: ×6.12, Anomalous: ×6.09).

주요 지표 상세 비교

지표	만건 버전 (~10K)	6만건 버전 (61K)	배율 / 변화
전체 요청 수	~10,000건	61,065건	×6.1
정상 요청 (Normal)	~5,884건	36,000건	×6.12
공격 요청 (Anomalous)	~4,116건	25,065건	×6.09

셀 번호	분석 항목	만 건 버전	6만 건 버전
[8]	공격 키워드 Top 15	동일	동일
[9]	키워드 상세 표	동일	동일
[10]	정상 vs 공격 요청 직접 비교	동일	동일
[11]	키워드 검색 인터랙티브	동일	동일

✓ 두 노트북의 **코드 구조는 완전히 동일**합니다. 데이터 파일 경로(read_csv 인자)만 다르며, 분석 로직·시각화 방식·공격 카테고리 정의 모두 동일합니다. 즉 동일 코드베이스로 서로 다른 규모의 데이터를 분석하는 구조입니다.

핵심 발견 및 시사점

01

클래스 비율의 안정성

샘플 크기가 6배 증가해도 공격 비율은 41%로 완전히 동일하게 유지됩니다. CSIC 2010 데이터셋이 일관된 클래스 분포를 갖는다는 것을 시사하며, 머신러닝 학습 시에도 동일한 클래스 불균형을 고려해야 합니다.

02

HTTP 메서드 구성의 일관성

GET(70.6%), POST(28.8%), PUT(0.65%) 비중이 두 데이터셋에서 동일합니다. 메서드별 공격 집중도 역시 동일 — PUT이 가장 위험(~99%), POST가 그 다음(~55%).

03

6만건 버전의 분석 적합성 우위

키워드 빈도 분석, 히스토그램 분포, Box Plot의 통계적 안정성 모두 6만건 버전이 유리합니다. 특히 희귀 공격 패턴(CRLF Injection 등)의 검출 신뢰도가 향상됩니다.

04

모델 학습 데이터로서의 차이

만건 버전은 탐색적 분석(EDA) 및 빠른 프로토타이핑에 적합하고, 6만건 버전은 실제 분류 모델 학습(TF-IDF + 분류기)에 더 적합합니다. 두 노트북을 목적에 따라 구분 사용하는 전략이 권장됩니다.