

MoodMate: 텍스트 기반 감정 분석 및 맞춤 추천 서비스

- 이름 / 학번: 박주원 / 20232500
- 데이터 출처 / 라이선스: HuggingFace `dair-ai/emotion` (<https://huggingface.co/datasets/dair-ai/emotion>) / MIT License

1. 문제 정의

현대인은 바쁜 일상 속에서 자신의 감정 상태를 명확히 인식하지 못하는 경우가 많다. 일기나 메모처럼 짧은 한 문장으로 오늘의 기분을 표현했을 때, 그 감정이 무엇인지 자동으로 분류하고 그에 맞는 활동이나 콘텐츠를 추천해 준다면 심리적 자기 인식을 높이는 데 도움이 될 수 있다. 본 프로젝트는 영어·한국어 감정 텍스트 데이터를 학습하여 사용자의 짧은 문장에서 감정을 예측하고, 감정별 맞춤 활동을 추천하는 웹 서비스를 구축하는 것을 목표로 한다.

- 예측 대상(target): 입력 문장의 감정 클래스 6종 — `sadness`(슬픔), `joy`(기쁨), `love`(사랑), `anger`(분노), `fear`(두려움), `surprise`(놀라움)

2. 데이터 소개 & EDA

데이터 규모 및 형식

항목	내용
데이터셋	<code>dair-ai/emotion</code> (HuggingFace Datasets)
train / validation / test	16,000 / 2,000 / 2,000 행
컬럼	<code>text</code> (영어 단문), <code>label</code> (감정 정수 0~5)
클래스 수	6종 (sadness, joy, love, anger, fear, surprise)
로컬 로그	<code>emotion_log.csv</code> — datetime, text, emotion, emotion_korean, confidence, recommended_action

EDA에서 발견한 사실

- 클래스 불균형: `joy` 와 `sadness` 가 전체 데이터의 과반을 차지하며, `love` 와 `surprise` 는 상대적으로 적다. 이는 모델이 소수 클래스를 덜 정확하게 예측할 수 있는 위험 요인이다.
- 감정별 문장 길이 차이: `love` · `joy` 계열 문장이 `anger` · `fear` 보다 평균 단어 수가 많다. 감정 표현의 풍부함과 어휘 다양성이 감정 유형마다 다를 수 있다.
- 특정 어휘의 감정 집중: TF-IDF 가중치 상위 단어를 보면 `feel`, `like`, `im`, `love` 등 감정 동사·형용사가 전체 분류에서 높은 기여도를 보이며, 각 감정별로 대표 어휘가 뚜렷하게 구분된다.

결측·이상치 처리

- HuggingFace `datasets` 로 로드 시 `text` · `label` 컬럼에 결측값 없음 (공식 데이터셋).
- 빈 문자열 또는 공백만 있는 입력은 앱 레벨에서 사전 차단 (입력 유효성 검사).
- 수치형 이상치 없음 — 텍스트 길이 분포를 확인한 결과 극단적으로 긴 문장이 없어 원본 데이터를 유지하였다.

3. 특성 엔지니어링

새 특성	생성 방법	사용 근거
<code>text_length</code>	문장의 문자 수 계산	감정별 표현 길이 차이를 확인하기 위해 사용
<code>word_count</code>	공백 기준 토큰 수 계산	감정별 평균 단어 수 비교 및 EDA 시각화에 활용
<code>emotion</code>	숫자 라벨 → 감정명 문자열 변환	시각화·결과 해석을 쉽게 하기 위해 사용
한국어 키워드 매핑	유니코드 범위(가~힉)로 한국어 감지 → 감정별 키워드 사전(6종 × 9~15개)으로 매칭 → 표준 영어 문장으로 변환	영어 전용 모델로 한국어 입력을 처리하기 위한 하이브리드 설계

한국어 키워드 매핑은 데이터셋이 영어 기반임에도 실사용 환경을 고려한 설계로, 별도 다국어 모델 없이 언어 장벽을 극복하기 위해 도입하였다.

4. 모델 / 서비스

사용한 방법: 전통 머신러닝 (TF-IDF + Logistic Regression)

딥러닝·LLM 대신 전통 ML을 선택한 이유:

- 6-클래스 단문 감정 분류에서 Logistic Regression은 해석 가능성이 높고 학습·추론 속도가 빠르다.
- GPU 없이 로컬 환경에서 안정적으로 동작하며 `pkl` 파일로 모델을 저장·재사용할 수 있다.
- 수업 프로젝트의 목적이 복잡한 모델보다 데이터 분석 → 모델링 → 서비스화의 전체 흐름 구현에 있으므로, 가볍고 설명 가능한 모델을 선택하였다.

입력 → 출력 흐름



성능 지표

평가 지표	값
Accuracy	0.87
Macro avg F1-score	0.81
Weighted avg F1-score	0.87

감정	Precision	Recall	F1-score	Support
sadness	0.91	0.92	0.91	581
joy	0.85	0.95	0.90	695
love	0.80	0.65	0.72	159
anger	0.89	0.83	0.86	275
fear	0.87	0.82	0.84	224
surprise	0.89	0.50	0.64	66

5. Streamlit 앱

페이지 구성 (4개 탭)

탭	주요 내용
서비스 소개	프로젝트 배경, 데이터셋 설명, 서비스 흐름 안내
데이터 분석	데이터셋 미리보기, 감정 분포 차트, 감정별 평균 단어 수, 예시 문장
감정 예측	텍스트 입력 → 감정 예측 결과 카드 + 확률 막대 그래프 + 맞춤 추천
감정 기록	누적 예측 이력 테이블, 분포 차트, 최근 5건 요약, CSV 내보내기

1. 서비스 소개



오늘의 문장으로 알아보는 기분 맞춤 콘텐츠 추천 서비스

문장을 입력하면 감정을 분석하고 감정에 맞는 콘텐츠와 행동을 추천합니다. 영어 문장은 모델이 직접 분석하고 한국어 문장은 감정 키워드를 먼저 감지해 분석합니다.

[서비스 소개](#) [데이터 분석](#) [감정 예측](#) [감정 기록](#)

프로젝트 소개

MoodMate는 사용자가 작성한 짧은 문장을 바탕으로 감정을 분석하고 감정 유형에 따라 적절한 콘텐츠와 행동을 추천하는 서비스입니다.

사용 데이터

- 데이터셋: HuggingFace `dair-ai/emotion`
- 데이터 형태: 영어 텍스트 문장 + 감정 라벨
- 감정 라벨: sadness, joy, love, anger, fear, surprise
- 모델: TF-IDF + Logistic Regression

서비스 흐름

1. 사용자가 오늘의 기분 문장을 입력합니다.
2. 입력 문장의 감정을 예측합니다.
3. 예측된 감정에 맞는 콘텐츠와 행동을 추천합니다.
4. 감정별 예측 확률을 그래프로 보여줍니다.
5. 분석 결과를 감정 로그로 저장하고 누적 기록을 확인합니다.

2. 데이터 분석

데이터 분석

데이터 미리보기

	text	label	emotion	%
0	i didnt feel humiliated	0	sadness	
1	i can go from feeling so hopeless to so damned hopeful just from being around some	0	sadness	
2	im grabbing a minute to post i feel greedy wrong	3	anger	
3	i am ever feeling nostalgic about the fireplace i will know that it is still on the propert	2	love	
4	i am feeling grouchy	3	anger	

감정별 데이터 개수



감정별 평균 단어 수



감정별 예시 문장

예시를 보고 싶은 감정을 선택하세요.

sadness

- i didnt feel humiliated
- i can go from feeling so hopeless to so damned hopeful just from being around someone who cares and is awake
- ive been feeling a little burdened lately wasnt sure why that was
- i feel like i have to make the suffering i m seeing mean something
- i feel low energy i m just thirsty

3. 감성예측

감정 예측

오늘의 기분을 문장으로 적어보세요.

예: 오늘은 너무 지치고 외로운 하루였어 / i feel tired and lonely today.

감정 분석하기

4. 감정 기록

감정 기록

누적 감정 기록

	datetime	text	emotion	emotion_korean	confidence
0	2026-06-08 00:38:42	내일 발표가 있어서 너무 불안하고 걱정된다	fear	불안/두려움	99.14

내 감정 분포



최근 기록

2026-06-08 00:38:42 | 불안/두려움 | 99.14%

내일 발표가 있어서 너무 불안하고 걱정된다

감정 기록 CSV 다운로드

감정 기록 전체 삭제

6. 결론 & 한계

알게 된 것

- 짧은 감정 문장 분류에서 TF-IDF + Logistic Regression 조합은 높은 신뢰도를 보여, 복잡한 딥러닝 없이도 실용적인 성능을 달성할 수 있음을 확인하였다.
- 한국어 입력을 키워드 사전으로 영어 문장에 매핑하는 하이브리드 접근법이 다국어 지원의 현실적인 대안임을 알게 되었다.
- 데이터 분석·모델링 결과를 실제 사용자 흐름(추천·기록)에 연결하는 것이 서비스 완성도에 중요하다는 점을 배웠다.

아쉬운 점 / 향후 과제

- 한국어 지원 고도화:** 현재 키워드 사전 기반 매핑은 사전에 없는 표현을 처리하지 못한다. 한국어 전용 감정 데이터셋(예: AIHub 감성 대화 말뭉치)으로 별도 모델을 학습하거나 KoBERT-KLUE-BERT 같은 사전학습 모델을 적용하면 정확도를 크게 높일 수 있다.
- 클래스 불균형 해소:** SMOTE 또는 `class_weight='balanced'` 옵션을 적용해 소수 클래스(`love`, `surprise`)의 예측 성능을 개선할 여지가 있다.
- LLM 활용:** Claude나 GPT 같은 사전학습 LLM을 API로 연동하면 맥락을 고려한 더 정교한 감정 분석과 자연스러운 추천 문구 생성이 가능하다.
- 개인화 추천:** 사용자의 누적 감정 기록을 분석해 자주 나타나는 감정 패턴에 따라 개인화된 콘텐츠를 우선 추천하는 방향으로 확장할 수 있다.
- 감정 트렌드 시각화:** 시계열 감정 변화 그래프를 추가하면 사용자가 장기적인 감정 흐름을 추적하는 데 도움이 된다.